

ACTIVIDAD OPCIONAL-SEMANA 1

PAULA XIMENA ROMERO VILLEGAS

DOCENTE: JESUS ARIEL

MATERIA: CIENCIA DE DATOS

CORPORACIÓN UNIVERSITARIA DEL HUILA
(CORHUILA)

Entrega Semana 1

Ciencia de Datos

Caso elegido: planta agroindustrial del Huila que tuesta y empaca café. La línea de empaque L2 mueve cerca del 60 % del volumen despachado y opera en dos turnos.

1. Problema real y pregunta de negocio

El problema

El mantenimiento de la línea L2 es reactivo: la máquina se interviene cuando ya falló. La planta registra en promedio cuatro paradas no programadas por semana, de unos 45 minutos cada una. Cada parada obliga a purgar el producto en tránsito, reprogramar despachos y, en temporada de cosecha, pagar horas extra para recuperar el plan.

El costo no está solo en el tiempo perdido. Está en que nadie sabe *qué* va a fallar ni *cuándo*, así que no se pueden aprovechar las ventanas en las que la línea ya está detenida por otra razón (cambio de referencia, fin de turno, aseo de fin de semana). Intervenir dentro de esas ventanas cuesta una fracción de lo que cuesta una parada sorpresa a mitad de turno.

La pregunta

¿Cuál es la probabilidad de que la línea de empaque L2 sufra una parada no programada en las próximas 72 horas, y qué equipo o componente sería el causante más probable?

Preguntas secundarias que la acompañan:

- ¿Qué variables anticipan la falla con al menos 12 horas de antelación?
- ¿Qué modos de falla concentran la mayor pérdida de tiempo productivo?

(Una pregunta de negocio sirve cuando puede convertirse en una tarea de datos concreta y su respuesta cambia algo que alguien ya decide. Provost y Fawcett insisten en este punto: el trabajo más difícil de un proyecto de datos no es modelar, es traducir un problema de negocio en una tarea de minería de datos bien definida [1]. CRISP-DM le dedica toda su primera fase, *Business Understanding*, y advierte que un proyecto que arranca en los datos en vez de en la decisión suele terminar produciendo respuestas correctas a preguntas que a nadie le importan [2]).

Esta pregunta cumple cuatro condiciones:

Condición	Cómo se cumple aquí
Unidad de análisis definida	La línea L2 y sus equipos, no "la planta" en abstracto.
Ventana temporal explícita	72 horas, que es el horizonte en el que el programador de producción todavía puede mover el plan.
Salida medible	Una probabilidad y un componente señalado, no una opinión.
Decisión asociada	Adelantar o no una intervención (ver punto 3).

Comparada con una versión mal formulada — "*¿cómo mejoramos el mantenimiento de la planta?*" — la diferencia es que esta última no dice sobre qué activo, en qué plazo, ni quién haría algo distinto con la respuesta.

2. Datos necesarios y fuentes

Dato	Detalle	Fuente	Granularidad
Señales de máquina	Vibración, temperatura de rodamientos, corriente del motor, presión de aire	Sensores IoT / PLC vía SCADA	1 min
Historial de mantenimiento	Órdenes correctivas y preventivas, repuestos cambiados, horas-hombre	CMMS o módulo PM del ERP	Por evento
Registro de paradas	Hora de inicio y fin, causa codificada, turno	Bitácora de OEE / MES	Por evento
Plan y ejecución de producción	Referencia empacada, velocidad, cambios de formato, unidades por turno	ERP / MES	Por turno y lote
Calidad de insumos	Humedad del grano, lote de proveedor, calibre de la película de empaque	Laboratorio de calidad y Compras	Por lote
Condiciones ambientales	Temperatura y humedad relativa de planta	Sensores de planta; IDEAM como respaldo externo	1 hora
Contexto operativo	Turno, cuadrilla, antigüedad y ficha técnica del activo	Nómina (anonimizada) y maestro de activos	Por turno

Horizonte: entre 18 y 24 meses de histórico. Menos de eso no alcanza a cubrir dos temporadas de cosecha ni a acumular suficientes eventos de falla para entrenar algo confiable.

Por qué estos datos y no otros

Las señales de sensores son las que aportan la anticipación: el fundamento del mantenimiento predictivo es que la mayoría de los componentes mecánicos degrada de forma detectable antes de fallar, y que vibración, temperatura y consumo de corriente son los indicadores más usados para captar esa degradación. Pero solas no bastan. Sin el historial de mantenimiento y el registro de paradas no hay **variable objetivo**: son esas dos fuentes las que dicen cuándo hubo falla y de qué tipo, y sin etiquetas no hay modelo supervisado.

Los datos de producción y de insumos entran porque la falla casi nunca depende solo de la máquina. Un lote de grano con humedad fuera de rango o una película de empaque de calibre distinto cambian el esfuerzo sobre la selladora. Ignorar esas variables lleva a un modelo que atribuye a la máquina lo que en realidad viene del proceso.

3. Decisión o acción que habilita el resultado

Quién decide	Jefe de mantenimiento junto con el programador de producción
Cuándo	Reunión diaria de las 7:00 a. m.
Qué decide	Si se adelanta una intervención sobre un equipo señalado por el modelo, en qué ventana se hace (cambio de referencia, fin de turno o parada del sábado) y si se reserva el repuesto crítico asociado

Qué cambia frente a hoy

Esa reunión ya existe. Hoy se hace con la bitácora del día anterior y la experiencia del equipo. Con el modelo, entra a la mesa una lista corta de equipos ordenados por riesgo a 72 horas, con el componente sospechoso y la antelación estimada.

El cambio operativo concreto es convertir **paradas no programadas de 45 minutos** en **intervenciones planificadas de 15 minutos** ejecutadas dentro de ventanas en las que la línea ya está detenida.

Por qué este punto define el proyecto?

Es la parte que más proyectos de analítica pierde. Davenport y Harris argumentan que el valor de la analítica no aparece en el modelo sino en el proceso de decisión donde se inserta: si el resultado no llega a la persona correcta, en el momento correcto y en un formato que pueda usar, el proyecto no produce nada aunque el modelo sea bueno. Provost y Fawcett hacen el mismo señalamiento desde el otro lado: conviene diseñar el proyecto empezando por la acción que se quiere habilitar y devolverse hasta los datos.

Por eso la salida del modelo se define desde ahora con la forma que necesita la reunión de las 7:00 a. m. — una lista priorizada, no un reporte de 20 páginas — y por eso el requisito de **12 horas de antelación mínima** no es un capricho técnico: es el tiempo que toma conseguir un repuesto crítico. Un modelo que avise con dos horas es inútil aunque acierte siempre.

4. Tipo de analítica

La clasificación estándar en la industria ordena la analítica en cuatro niveles según la pregunta que responde y el valor que entrega; la versión más citada es el modelo de madurez de Gartner (*Analytic Ascendancy Model*), que va de descriptiva a diagnóstica, predictiva y prescriptiva [9].

Nivel	Pregunta que responde	Papel en este proyecto
Descriptiva	¿Qué pasó?	Fase previa obligatoria
Diagnóstica	¿Por qué pasó?	Fase previa obligatoria
Predictiva	¿Qué va a pasar?	Objetivo principal
Prescriptiva	¿Qué debería hacer?	Fase 2, deseada

Objetivo principal es: analítica predictiva

La pregunta pide una probabilidad sobre un evento futuro, así que el corazón del proyecto es predictivo. En términos de tarea de minería de datos, se plantea como:

- **Clasificación binaria:** ¿habrá parada no programada en L2 en las próximas 72 horas? Sí / No.
- **Salida secundaria multiclase:** ¿cuál es el componente más probablemente responsable?

Justificación de la elección

El tipo de analítica no se escoge por preferencia técnica, sino que queda determinado por la pregunta de negocio y por la decisión que se quiere habilitar. En este caso la pregunta pide una **probabilidad sobre un evento que aún no ha ocurrido** —una parada en las próximas 72 horas—, y esa formulación solo puede responderse con analítica predictiva. Ningún otro nivel entrega esa salida.

Los tres niveles restantes se descartan como objetivo principal por razones concretas:

- **Descriptiva.** Responde qué pasó. Puede decir cuántas paradas hubo el mes pasado y cuánto tiempo costaron, pero no anticipa nada. El jefe de mantenimiento ya tiene esa información en la bitácora y sigue sin poder actuar antes de la falla.

- **Diagnóstica.** Responde por qué pasó. Es útil para entender los modos de falla dominantes, pero explica eventos ya ocurridos. No indica cuándo llegará el siguiente, que es justo lo que la reunión de las 7:00 a. m. necesita saber.
- **Prescriptiva.** Responde qué debería hacerse. Es el destino deseable del proyecto, pero exige dos cosas que hoy no existen: una predicción ya validada y confiable, y datos de costo de intervención, disponibilidad de repuestos y penalización por incumplimiento con los que optimizar. Intentar prescribir sin una predicción confiable produce recomendaciones que el equipo no va a seguir.

Además, el problema cumple las condiciones que hacen viable un modelo predictivo supervisado: existe una **variable objetivo observable y etiquetable** (la parada quedó registrada en la bitácora y en el CMMS), existe **histórico suficiente** para entrenar, y existen **señales medidas antes del evento** que pueden actuar como predictoras. Cuando alguna de estas tres condiciones falta, la analítica predictiva deja de ser una opción realista por más que la pregunta la sugiera. Por último, la elección es coherente con la decisión que se quiere habilitar. El valor no está en predecir por predecir, sino en que una probabilidad a 72 horas con al menos 12 de antelación es exactamente lo que permite mover una intervención desde una parada sorpresa hacia una ventana ya detenida. Si la decisión requiriera otro horizonte, el tipo de analítica cambiaría con ella.

Hacia dónde debería evolucionar

La versión prescriptiva sería recomendar la **ventana óptima de intervención**, optimizando entre el riesgo de falla, el plan de producción comprometido, la disponibilidad de repuestos y el costo de parar. Es la fase 2 del proyecto: exige que la predicción ya sea confiable y que el equipo confíe en ella.

Referencias

1. Provost, F. y Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.
2. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step Data Mining Guide*. The CRISP-DM Consortium / SPSS.
3. Mobley, R. K. (2002). *An Introduction to Predictive Maintenance* (2.^a ed.). Butterworth-Heinemann.
4. ISO (2016). *ISO 14224:2016 — Petroleum, petrochemical and natural gas industries: Collection and exchange of reliability and maintenance data for equipment*. International Organization for Standardization.
5. Redman, T. C. (2016). "Bad Data Costs the U.S. \$3 Trillion Per Year". *Harvard Business Review*, 22 de septiembre de 2016.
6. Congreso de la República de Colombia (2012). *Ley 1581 de 2012*, por la cual se dictan disposiciones generales para la protección de datos personales; y Decreto 1377 de 2013 (reglamentario).
7. Nakajima, S. (1988). *Introduction to TPM: Total Productive Maintenance*. Productivity Press.
8. Davenport, T. H. y Harris, J. G. (2007). *Competing on Analytics: The New Science of Winning*. Harvard Business School Press.