

ACTIVIDAD PRÁCTICA - SEMANA 2

PAULA XIMENA ROMERO VILLEGAS

DOCENTE: JESUS ARIEL

MATERIA: CIENCIA DE DATOS

CORPORACIÓN UNIVERSITARIA DEL HUILA
(CORHUILA)

2026

ACTIVIDAD PRÁCTICA

(semana-2)

1. Lista al menos 6 fuentes de datos de tu caso y clasifícalas: estructurado / semiestructurado / no estructurado.

Caso de estudio:

Planta agroindustrial del Huila que tuesta y empaca café. El proyecto analiza la línea de empaque L2, que mueve aproximadamente el 60 % del volumen despachado y opera en dos turnos. El objetivo principal es estimar la probabilidad de una parada no programada en las próximas 72 horas e identificar el equipo o componente más probable como causante de la falla.

1.Fuentes de datos y clasificación por estructura

Para este caso se identifican las siguientes fuentes de datos. La clasificación se realiza según la forma en que los datos se almacenan y el nivel de estructura que presentan.

Fuente de datos	Ejemplos de datos	Clasificación	Justificación
Sensores IoT / PLC vía SCADA	Vibración, temperatura de rodamientos, corriente del motor y presión de aire.	Estructurado	Las mediciones se registran con variables definidas, fecha y hora, equipo y valor numérico; pueden organizarse en tablas o series de tiempo.
CMMS o módulo PM del ERP	Órdenes correctivas y preventivas, repuestos cambiados y horas-hombre.	Estructurado	Los registros de mantenimiento siguen campos definidos y relaciones claras entre equipos, órdenes, fechas y actividades.
Bitácora de OEE / MES	Hora de inicio y fin de la parada, causa codificada y turno.	Estructurado	Cada evento puede almacenarse en columnas predefinidas y consultarse fácilmente para análisis estadístico.
ERP / MES de producción	Referencia empacada, velocidad de producción, cambios de formato y unidades por turno o lote.	Estructurado	Los datos operativos se organizan mediante registros y campos estandarizados para cada lote o turno.

Laboratorio de calidad y Compras	Humedad del grano, lote del proveedor y calibre de la película de empaque.	Estructurado	Las variables de calidad y trazabilidad tienen formatos definidos y valores medibles asociados a un lote.
Sensores ambientales / IDEAM	Temperatura y humedad relativa de la planta, registradas por hora.	Estructurado	Son observaciones numéricas con una frecuencia y una marca de tiempo definidas.
Archivos de registro y mensajes técnicos del SCADA	Logs de alarmas, códigos de eventos y mensajes generados por los equipos.	Semiestructurado	Aunque contienen información organizada por etiquetas, códigos o marcas de tiempo, pueden incluir campos variables y texto técnico.
Observaciones y reportes libres del personal de mantenimiento	Comentarios sobre ruidos, vibraciones anormales o condiciones observadas durante una revisión.	No estructurado	La información puede estar escrita en texto libre y no seguir un formato fijo, por lo que requiere procesamiento adicional para analizarla.

2. V del Big Data críticas para el caso

En este proyecto las cinco V son relevantes, pero no todas tienen el mismo nivel de criticidad. La prioridad está relacionada con la necesidad de anticipar fallas y convertir los datos en decisiones de mantenimiento.

V	Nivel de criticidad	Importancia en el caso
Veracidad	Muy crítica	Las decisiones de mantenimiento dependen de datos confiables. Un sensor mal calibrado, una parada mal registrada o una causa de falla incorrecta puede producir predicciones equivocadas y llevar a intervenir un equipo que no lo necesita.
Velocidad	Muy crítica	Las señales de la máquina pueden llegar cada minuto y la información debe procesarse con suficiente rapidez para detectar cambios antes de una falla. La utilidad del proyecto depende de generar alertas con la antelación necesaria.
Variedad	Muy crítica	El modelo necesita combinar señales de sensores, historial de mantenimiento, registros de paradas, producción, calidad de insumos y condiciones ambientales. Las fuentes tienen diferentes formatos y niveles de detalle.
Volumen	Crítica	Al registrar datos cada minuto durante entre 18 y 24 meses, y combinar varias fuentes y equipos, se acumula una cantidad considerable de datos históricos que debe almacenarse y procesarse eficientemente.
Valor	Crítica	El proyecto solo genera valor si las predicciones permiten reducir paradas no programadas, planificar intervenciones y aprovechar ventanas de mantenimiento sin afectar innecesariamente la producción.

Conclusión sobre las V. La veracidad es la V más importante porque la calidad de los datos determina la confiabilidad del análisis. La velocidad y la variedad también son fundamentales para anticipar fallas a partir de fuentes heterogéneas. El volumen debe gestionarse adecuadamente, mientras que el valor representa el beneficio final: transformar datos en acciones de mantenimiento más oportunas.

3. Posible problema de veracidad y cómo detectarlo

Posible problema de veracidad: lecturas anómalas o incorrectas de los sensores de vibración y temperatura debido a una mala calibración, fallas de comunicación o valores faltantes.

¿Por qué sería un problema? Si un sensor reporta una temperatura muy alta por un error técnico y no por una condición real de la máquina, el modelo podría interpretar ese dato como una señal de falla. De igual manera, valores faltantes o registros duplicados pueden alterar las tendencias utilizadas para entrenar y evaluar el modelo predictivo.

¿Cómo detectarlo?

- **Reglas de rango:** Definir límites operativos esperados para cada variable. Por ejemplo, identificar temperaturas, vibraciones o presiones físicamente imposibles o fuera de los rangos normales del equipo.
- **Comparación con sensores relacionados:** Contrastar las mediciones con otras variables y con el comportamiento histórico. Un cambio extremo en una sola señal, sin cambios en variables relacionadas, puede indicar un error de medición.
- **Detección de valores faltantes y duplicados:** Revisar la continuidad de las series de tiempo e identificar minutos sin lectura, registros repetidos o marcas de tiempo inconsistentes.
- **Comparación con eventos reales:** Verificar si las alertas o valores anómalos coinciden con paradas registradas en la bitácora, inspecciones técnicas o mantenimientos realizados.
- **Control de calidad periódico:** Revisar la calibración de sensores y documentar las intervenciones técnicas para diferenciar una condición real de una falla del sistema de medición.

Ejemplo aplicado al caso. Si la temperatura de un rodamiento aumenta repentinamente de un valor normal a un valor extremadamente alto en un solo minuto y después vuelve inmediatamente a la normalidad, sin que exista una parada ni evidencia de una anomalía en el equipo, el dato debe marcarse como sospechoso. Antes de usarlo para el modelo, se debe revisar el sensor, la comunicación y el registro original.

Conclusión

El caso de la línea de empaque L2 combina principalmente datos estructurados procedentes de sensores, sistemas de mantenimiento, producción y calidad, pero también puede incorporar información semiestructurada y no estructurada. Las V más críticas son veracidad, velocidad, variedad y valor, debido a que el objetivo es detectar señales de falla con suficiente anticipación y convertirlas en decisiones operativas. Por esta razón, la validación de la calidad de los datos es una condición esencial antes de construir un modelo predictivo.

Referencias

1. Provost, F. y Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.
2. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). CRISP-DM 1.0: Step-by-step Data Mining Guide. The CRISP-DM Consortium / SPSS.
3. Mobley, R. K. (2002). An Introduction to Predictive Maintenance (2.^a ed.). Butterworth-Heinemann.
4. Redman, T. C. (2016). Bad Data Costs the U.S. \$3 Trillion Per Year. Harvard Business Review, 22 de septiembre de 2016.
5. Davenport, T. H. y Harris, J. G. (2007). Competing on Analytics: The New Science of Winning. Harvard Business School Press.