

# **ACTIVIDAD PRÁCTICA - SEMANA 3**

**PAULA XIMENA ROMERO VILLEGAS**

**DOCENTE: JESUS ARIEL**

**MATERIA: CIENCIA DE DATOS**

**CORPORACIÓN UNIVERSITARIA DEL HUILA**  
**(CORHUILA)**

2026


# GUÍA DE ACTIVIDAD PRÁCTICA


## Caso de estudio

**Planta agroindustrial del Huila que tuesta y empaqa café.** Se utiliza nuevamente el caso de la línea de empaque L2. La línea genera datos de sensores, mantenimiento, producción, calidad y condiciones ambientales. El propósito de la arquitectura es integrar estas fuentes para analizar el comportamiento de la línea, detectar patrones de falla y apoyar decisiones de mantenimiento.

## 1. Arquitectura de datos: fuentes → ingesta → almacenamiento → procesamiento → análisis/BI

Arquitectura propuesta (diagrama ASCII)





- **Fuentes de datos.** La arquitectura inicia con los sistemas que producen información sobre la operación. Los sensores generan series de tiempo, mientras que el CMMS, ERP y MES aportan información estructurada sobre mantenimiento y producción.
- **Ingesta.** Las señales y eventos frecuentes ingresan por streaming. Los históricos, órdenes de mantenimiento y datos operativos se cargan por procesos batch programados.
- **Almacenamiento.** Los datos se conservan en un Data Lake/Lakehouse para recibir información de diferentes formatos y mantener datos crudos y datos preparados.
- **Procesamiento.** Se realizan limpieza, validación, eliminación de duplicados, manejo de valores faltantes, integración de fuentes y creación de variables analíticas.
- **Análisis y BI.** Los datos preparados se muestran en tableros con indicadores de paradas, comportamiento de sensores, tendencias y riesgo para facilitar decisiones.

## 2. Justificación: ¿Data Lake o Data Warehouse? ¿Batch o Streaming?

### 2.1. Decisión de almacenamiento: Data Lake / Lakehouse

Para este caso se propone utilizar una arquitectura de Data Lake, idealmente evolucionada hacia un Lakehouse. La razón principal es la variedad de las fuentes: existen datos estructurados del ERP y CMMS, series de tiempo de sensores, archivos de registros y posibles observaciones en texto. Un Data Lake permite conservar información de diferentes formatos y mantener los datos originales para futuros análisis.

La organización por capas permite mejorar progresivamente la calidad. En Bronze se almacenan datos crudos; en Silver se limpian, validan e integran; y en Gold se preparan los datos de mayor calidad para indicadores, BI y modelos analíticos. Esta estructura permite usar una misma base para análisis histórico y mantenimiento predictivo.

**¿Por qué no solamente un Data Warehouse?** Un Warehouse sería útil para la parte final de reportes, pero como solución única sería menos flexible para conservar datos crudos de sensores y otras fuentes heterogéneas antes de su transformación.

**2.2. Decisión de procesamiento: enfoque híbrido Batch + Streaming**

La mejor alternativa es combinar ambos enfoques. Streaming es adecuado para señales de sensores y eventos que llegan continuamente, porque permite detectar cambios recientes. Batch sigue siendo necesario para cargar y actualizar históricos de mantenimiento, producción, calidad y otros sistemas que no requieren actualización inmediata.

| Tipo      | Aplicación en el caso                          | Justificación                                                            |
|-----------|------------------------------------------------|--------------------------------------------------------------------------|
| Streaming | Sensores IoT, PLC, SCADA y eventos continuos.  | Permite procesar datos recientes y detectar cambios con baja latencia.   |
| Batch     | CMMS, producción, calidad y cargas históricas. | Es eficiente para procesar conjuntos de datos en intervalos programados. |
| Híbrido   | Integración de todas las fuentes.              | Combina actualización continua con análisis histórico.                   |

**Conclusión de la decisión.** La arquitectura utiliza Data Lake/Lakehouse como base y un modelo híbrido batch + streaming, ajustado a la variedad de información de la planta y a la necesidad de integrar datos históricos con señales continuas.

### 3. Herramientas candidatas por etapa y justificación

| Etapa          | Herramienta candidata                         | Uso                                                           | ¿Por qué?                                                                            |
|----------------|-----------------------------------------------|---------------------------------------------------------------|--------------------------------------------------------------------------------------|
| Ingesta        | Apache Kafka                                  | Recibir y distribuir eventos y señales continuas.             | Está orientado al event streaming y al manejo de eventos de sensores y aplicaciones. |
| Procesamiento  | Apache Spark / Structured Streaming           | Limpiar, transformar e integrar datos históricos y continuos. | Permite procesamiento escalable y APIs unificadas para batch y streaming.            |
| Almacenamiento | Data Lake/Lakehouse con Bronze, Silver y Gold | Guardar datos crudos, validados y listos para análisis.       | Permite integrar distintas fuentes y mejorar la calidad progresivamente.             |
| BI             | Microsoft Power BI                            | Crear tableros, indicadores y visualizaciones.                | Permite convertir datos preparados en información visual para apoyar decisiones.     |

#### Conclusión general

La arquitectura propuesta conecta las fuentes operativas de la línea L2 con una plataforma central de almacenamiento, procesamiento y análisis. La elección de un Data Lake/Lakehouse se justifica por la variedad de formatos y por la necesidad de conservar datos crudos. El enfoque híbrido batch + streaming permite aprovechar el histórico de la planta y procesar señales continuas. Con Apache Kafka para ingesta, Apache Spark para procesamiento y Power BI para visualización, se obtiene un flujo coherente desde la generación de los datos hasta la toma de decisiones.

## Referencias

1. Databricks. (2026). What is a data lakehouse? <https://docs.databricks.com/aws/en/lakehouse/>
2. Databricks. (2026). Data warehousing architecture. <https://docs.databricks.com/aws/en/sql/get-started/data-warehousing-concepts>
3. Apache Kafka. (2026). Introduction. <https://kafka.apache.org/documentation/>
4. Apache Spark. (2026). Spark Structured Streaming. <https://spark.apache.org/streaming/>
5. Microsoft. (2026). ¿Qué es Power BI? <https://learn.microsoft.com/es-es/power-bi/fundamentals/power-bi-overview>