

ACTIVIDAD PRÁCTICA - SEMANA 4

PAULA XIMENA ROMERO VILLEGAS

DOCENTE: JESUS ARIEL

MATERIA: CIENCIA DE DATOS

CORPORACIÓN UNIVERSITARIA DEL HUILA
(CORHUILA)

2026

GUÍA DE ACTIVIDAD PRÁCTICA

Caso de estudio

Planta agroindustrial del Huila que tuesta y empaca café. Se mantiene el caso de la línea de empaque L2. La línea genera datos de sensores, mantenimiento, producción, calidad y condiciones ambientales. El objetivo es analizar estos datos para conocer el comportamiento de la línea, comprender las causas de las paradas, estimar la probabilidad de fallas y apoyar decisiones de mantenimiento.

1. Cuatro preguntas, una por cada tipo de analítica

Las preguntas se formulan directamente a partir del caso de la línea de empaque L2. Cada una corresponde a un tipo diferente de analítica porque responde una necesidad distinta.

1.1. Analítica descriptiva

Pregunta: ¿Cuántas paradas no programadas tuvo la línea L2 durante el último mes y cuánto tiempo total estuvo detenida?

Justificación: Esta pregunta es descriptiva porque resume lo que ya ocurrió. Para responderla se utilizan registros históricos de paradas, fechas, duración y turnos. El resultado puede mostrarse mediante indicadores, tablas o gráficos que permitan conocer la frecuencia de las paradas y el tiempo perdido.

Resultado esperado: Obtener una visión clara del comportamiento histórico de la línea, identificando cuántas veces se detuvo y cuál fue el impacto total de esas detenciones.

1.2. Analítica diagnóstica

Pregunta: ¿Por qué aumentaron las paradas no programadas de la línea L2 durante determinados turnos o periodos?

Justificación: Esta pregunta es diagnóstica porque busca identificar las posibles causas del problema. Se relacionan los registros de parada con variables como vibración, temperatura, mantenimiento realizado, referencia producida, turno y condiciones ambientales. El análisis permite encontrar relaciones y patrones que ayuden a explicar lo observado.

Resultado esperado: Identificar factores asociados a las paradas, por ejemplo un componente con fallas repetitivas o un aumento de la vibración antes de una detención.

1.3. Analítica predictiva

Pregunta: ¿Cuál es la probabilidad de que la línea L2 presente una parada no programada en las próximas 72 horas?

Justificación: Esta pregunta es predictiva porque utiliza información histórica y actual para estimar un evento futuro. Se analizan patrones anteriores de fallas junto con las condiciones actuales de los sensores y el historial de mantenimiento. El objetivo es calcular una probabilidad o nivel de riesgo.

Resultado esperado: Generar una estimación del riesgo de parada para anticipar intervenciones y priorizar los equipos que requieren mayor atención.

1.4. Analítica prescriptiva

Pregunta: Si el modelo identifica una alta probabilidad de falla en un componente de la línea L2, ¿qué acción de mantenimiento debería realizarse y en qué momento para reducir el riesgo sin afectar innecesariamente la producción?

Justificación: Esta pregunta es prescriptiva porque busca recomendar qué decisión tomar. Parte de la información descriptiva y diagnóstica y puede utilizar el resultado predictivo para evaluar alternativas, considerando riesgo, disponibilidad de personal, repuestos y el impacto de detener la producción.

Resultado esperado: Proponer la acción más conveniente para disminuir el riesgo de una parada no programada y aprovechar mejor los recursos de mantenimiento.

Resumen de clasificación

Tipo de analítica	Pregunta central	¿Qué responde?
Descriptiva	¿Cuántas paradas ocurrieron y cuánto duraron?	¿Qué pasó?
Diagnóstica	¿Por qué aumentaron las paradas?	¿Por qué pasó?
Predictiva	¿Qué probabilidad existe de una parada en 72 horas?	¿Qué podría pasar?
Prescriptiva	¿Qué acción debería realizarse para reducir el riesgo?	¿Qué se debería hacer?

2. Uso de Machine Learning: supervisado o no supervisado

Para la analítica predictiva se utilizaría principalmente Machine Learning supervisado.

El objetivo es estimar la probabilidad de una parada no programada en las próximas 72 horas. Para entrenar un modelo se pueden utilizar datos históricos en los que ya se conoce el resultado final: periodos en los que ocurrió una parada y periodos en los que no ocurrió. Ese resultado conocido funciona como etiqueta o variable objetivo.

Las variables de entrada pueden incluir temperatura, vibración, corriente, presión, tiempo desde el último mantenimiento, referencia producida y comportamiento histórico. El modelo aprende la relación entre estas variables y la ocurrencia o no de una parada. Por esta razón, un enfoque supervisado es el más adecuado para la pregunta predictiva.

Ejemplo: clasificar cada periodo como “alto riesgo de parada” o “bajo riesgo de parada”, o calcular una probabilidad de falla a partir de registros históricos etiquetados.

En la parte prescriptiva no se depende únicamente de Machine Learning supervisado.

La analítica prescriptiva puede combinar el resultado predictivo con reglas de negocio, criterios de mantenimiento y métodos de optimización. Por ejemplo, si la probabilidad de falla supera un umbral y existe una ventana de mantenimiento disponible, el sistema puede recomendar una intervención preventiva.

¿Se podría usar aprendizaje no supervisado? Sí, como complemento para detectar comportamientos anómalos o agrupaciones de patrones cuando no existen etiquetas claras. Sin embargo, para predecir directamente una parada futura, el aprendizaje supervisado es la opción más relacionada con el objetivo.

3. Posible sesgo o riesgo ético y estrategia de mitigación

Riesgo identificado: sesgo en los datos históricos de mantenimiento y producción.

Un posible riesgo aparece si los datos históricos no representan de manera equilibrada todas las condiciones de operación. Por ejemplo, algunos turnos pueden tener registros más completos que otros o ciertas fallas pueden haberse documentado con mayor detalle dependiendo de quién realizó el reporte.

Si un modelo aprende a partir de datos incompletos o desequilibrados, podría asociar incorrectamente el riesgo de falla con un turno o condición de operación. Esto puede generar decisiones equivocadas o atribuciones injustificadas, cuando la causa real es la diferencia en la calidad de los registros.

¿Cómo mitigarlo?

- **Validar la calidad y cobertura de los datos.** Revisar si existen turnos, equipos o periodos con información incompleta antes de entrenar el modelo.
- **Estandarizar el registro de fallas.** Utilizar criterios y categorías claras para que las paradas y sus causas se registren de la misma manera.
- **Reducir variables que puedan generar atribuciones injustas.** Evitar datos personales o variables que no sean necesarias para explicar técnicamente el comportamiento de la máquina.
- **Evaluar el modelo por diferentes condiciones.** Comprobar si el desempeño cambia significativamente entre turnos, equipos o tipos de producción.
- **Mantener supervisión humana.** Las recomendaciones del sistema deben apoyar la decisión del personal técnico y no sustituir automáticamente su criterio profesional.
- **Documentar las decisiones.** Registrar qué datos se utilizaron y cómo se generó una recomendación facilita la transparencia y la revisión posterior.

Conclusión ética: El uso de analítica y Machine Learning puede mejorar la toma de decisiones, pero depende de la calidad, representatividad y uso responsable de los datos. El sistema debe orientarse a prevenir fallas técnicas y apoyar el mantenimiento, evitando atribuciones injustificadas sobre las personas.

Conclusión general

El caso de la línea de empaque L2 permite aplicar los cuatro tipos de analítica de forma complementaria. La analítica descriptiva muestra lo ocurrido, la diagnóstica ayuda a comprender las causas, la predictiva estima el riesgo futuro y la prescriptiva orienta las acciones. Para la predicción de paradas, el Machine Learning supervisado es el enfoque principal porque se dispone de información histórica que puede relacionarse con eventos conocidos. El uso de estos modelos debe acompañarse de controles de calidad, evaluación de posibles sesgos y supervisión humana para garantizar decisiones responsables.

Referencias

1. Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.
2. Davenport, T. H., & Harris, J. G. (2007). Competing on Analytics: The New Science of Winning. Harvard Business School Press.
3. IBM. (2024). What is machine learning? IBM. <https://www.ibm.com/think/topics/machine-learning>
4. NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology. <https://www.nist.gov/itl/ai-risk-management-framework>
5. UNESCO. (2021). Recommendation on the Ethics of Artificial Intelligence. UNESCO. <https://unesdoc.unesco.org/ark:/48223/pf0000381137>